

ROSiS - Vaja 7 (Nevronske mreže 1)

Izbrani parametri za nalaganje signala

Med ekstrakcijo značilk sem posamezne signale razdelil na 4s, 2s in 1s dele. To sem dosegel tako da sem signal preprosto delil na 7, 14 in 28 delov, saj so vsi signali bili dolžine 28s.

Izbrane metode za določitev značilnic

Zero crossing rate

zero_crossing_rate - Metoda prešteje kolikokrat signal prečka os x (amplituda = 0).

Parametri:

- **y** - signal
- **hop_length** - število vzorcev med zaporednima oknom; nastavljeno na $sr/4$

Tempo

tempo - Ocena tempa signala v BPM (Beats Per Minute).

Parametri:

- **y** - signal
- **sr** - vzorčevalna frekvenca

MFCC, Delta, Delta-delta

MFCC - Mel-frekvenčni kepsralni koeficienti opisujejo spektralno ovojnico zvoka na mel skali, ki posnema človeško zaznavo frekvenc.

Parametri:

- **y** - signal
- **sr** - vzorčevalna frekvenca
- **n_mfcc** - število koeficientov
- **n_fft** - velikost FFT okna (512)
- **hop_length** - korak med okni (160 vzorcev)
- **window** - oblika okna (Hammingovo okno velikosti 512)
- **fmin** - spodnja frekvenca (300 Hz)
- **fmax** - zgornja frekvenca (8000 Hz)
- **n_mels** - število mel filtrov (128)

Delta - Prvi odvod MFCC koeficientov skozi čas - opisuje kako se barva zvoka spreminja.

Parametri:

- *mffc* - Mel-frekvenlni kepstralni koeficienti

Delta-delta - Drugi odvod MFCC koeficientov - opisuje pospešek spremembe barve zvoka.

Parametri:

- *mffc* - Mel-frekvenlni kepstralni koeficienti
- *order* - red odvoda

Za vse tri značilke omenjene v tem podpoglavju, sem za njih izračunal standardni odklon ter povprečje in jih dal v vektor značilk.

Chroma STFT

chroma_stft - Izračuna kromatogram iz signala.

Parametri:

- *y* - signal
- *sr* - vzorčevalna frekvenca
- *n_fft* - velikost FFT okna (512)

Za značilko omenjeno v tem podpoglavju, sem izračunal standardni odklon ter povprečje in jih dal v vektor značilk.

Tonnetz

tonnetz - Predstavlja tonalne odnose med zvoki. Dobro opisuje harmonično strukturo.

Parametri:

- *y* - harmonična komponenta signala (pridobljena iz signala z `librosa.effects.harmonic`)
- *sr* - vzorčevalna frekvenca

Za značilko omenjeno v tem podpoglavju, sem izračunal standardni odklon ter povprečje in jih dal v vektor značilk.

Spectral contrast

spectral_contrast - Meri razliko med energijskimi vrhovi in dolinami v 7 frekvenčnih pasovih spektra. Visok kontrast nakazuje glasne in tihe dele (npr. metal), nizek kontrast pa enakomerno porazdeljeno energijo (npr. klasična glasba).

Parametri:

- ***y*** - signal
- ***sr*** - vzorčevalna frekvenca
- ***n_fft*** - velikost FFT okna (512)

Za značilko omenjeno v tem podpoglavju, sem izračunal standardni odklon ter povprečje in jih dal v vektor značilk.

RMS

rms - Koren povprečja kvadratov vzorcev (Root Mean Square). Meri povprečno glasnost signala skozi čas.

Parametri:

- ***y*** - signal

Za značilko omenjeno v tem podpoglavju, sem izračunal standardni odklon ter povprečje in jih dal v vektor značilk.

Hiperparametri nevronske mreže

Arhitektura

Plast	Tip	Nevroni	Aktivacija
Vhod	Input	82	-
Skrita 1	Dense	256	ReLU
Regularizacija 1	Dropout	-	0.3
Skrita 2	Dense	128	ReLU
Regularizacija 2	Dropout	-	0.3
Skrita 3	Dense	64	ReLU
Regularizacija 3	Dropout	-	0.2
Izhod	Dense	10	Softmax

Arhitektura sledi principu postopnega zmanjševanja ($256 \rightarrow 128 \rightarrow 64$), kar modelu omogoča da se postopoma nauči vse bolj abstraktnih reprezentacij značilk pred končno klasifikacijo.

Aktivacijska funkcija ReLU (Rectified Linear Unit) je bila izbrana za skrite plasti ker ne trpi za problemom izginjajočega gradienta in je računsko učinkovita.

Aktivacijska funkcija Softmax na izhodni plasti pretvori vrednosti v verjetnosti za vsakega od 10 žanrov - vsota vseh izhodni verjetnosti je vedno 1.

Dropout med učenjem naključno “ugasne” določen delež nevronov, kar preprečuje prekomerno učenje (overfitting). Vrednost 0.3 pomeni da se 30% nevronov ugasne v vsaki iteraciji. Pri zadnji plasti je vrednost manjša (0.2) ker bližje izhodu ne želimo preveč motiti že naučenih reprezentacij.

Optimizator in izgubna funkcija

- **Optimizator:** Adam z hitrostjo učenja `learning_rate = 0.001` - Adam adaptivno prilagaja hitrost učenja za vsak parameter posebej, kar vodi do hitrejše konvergence kot standardni SGD.
- **Izgubna funkcija:** `SparseCategoricalCrossentropy` - primerna za klasifikacijo z več razredi kjer so oznake cela števila (0-9).
- **Metrika:** `SparseCategoricalAccuracy` - meri delež pravilno klasificiranih vzorcev.

Parametri učenja

- **Število epoh:** 150 - zgornja meja, učenje se samodejno prekine prej z early stopping.
- **Velikost paketa (batch size):** 32 - kompromis med stabilnostjo gradientov in hitrostjo učenja.
- **Early stopping:** monitor `val_loss`, `patience = 10` - učenje se prekine če se validacijska izguba 10 epoh zapored ne izboljša.

- **Model checkpoint:** shranjuje samo najboljše uteži glede na `val_loss` - po končanem učenju se naložijo najboljše uteži.


Tabela Summary

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 256)	21,248
dropout (Dropout)	(None, 256)	0
dense_1 (Dense)	(None, 128)	32,896
dropout_1 (Dropout)	(None, 128)	0
dense_2 (Dense)	(None, 64)	8,256
dropout_2 (Dropout)	(None, 64)	0
dense_3 (Dense)	(None, 10)	650


Figure 1: img.png

Pravilnosti klasifikacije



[H]

Metrike izgube skozi učenje



[H]

Grafa prikazujeta metriko izgube (loss) in natančnosti (accuracy) skozi epohe učenja na učni in validacijski množici.

Acc train NN: 0.988

Acc test NN: 0.906